

건강 관련 변수가 보험료에 미치는 영향

| 박정혁 | 이준우 | 임예림 |

목 차

- 1 | 연구 주제 및 문제 배경
- 2 | 변수 변환 및 정의
- 3 | 분석 모형
- 4 | 변수선택법 및 모델 유의성 검정
- 5 | 회귀진단 및 결론
- 6 | 분석 한계점 및 우수성

연구 주제 및 문제 배경

01



01

연구 주제 및 문제 배경

문제 배경

■ 건강 관련 변수(bmi, 흡연 여부)가 보험료에 어떠한 영향을 미치는가?

- 리스크는 개인에게 경제적 비용을 발생시키며 나아가 사회 전체에도 비효율성 야기
- 개인의 입장에서 리스크를 헷지할 수 있는 대표적인 수단이 **보험**
- 보험사의 입장에서는 각기 다른 수준의 리스크를 보유한 소비자에게 적정 보험료 책정하는 것이 중요
- **건강 관련 변수가 보험료와 가장 관련 있을 것이라 판단**
- 대표 변수로 개인 건강에 치명적 영향을 끼치는 **흡연 여부와 bmi 선택**
- 건강 관련 변수로 대표되는 흡연 여부와 bmi가 보험료에 어떠한 유의미한 영향을 끼치는지,
나아가 개인의 특성과 관련된 변수를 고려한 모델 중 어떠한 모델이 보험료를 가장 잘 설명하는지 규명하고자 함

변수 변환 및 정의

02



02

변수 변환 및 정의

Interaction vs Group Dummy Variable

흡연 유무와 비만 여부에 따라 전체 데이터를 4개로 그룹핑 가능

	BMI < 30	BMI >= 30
흡연 X	Group1	Group2
흡연 O	Group3	Group4

smoke와 bmi의 교호작용을 고려할 경우 4개 그룹에 관여하는 변수는 아래와 같음


	BMI < 30	BMI >= 30
흡연 X	bmi	bmi
흡연 O	smoke*bmi + smoke + bmi	smoke*bmi + smoke + bmi

02


변수 변환 및 정의

Interaction vs Group Dummy Variable

smoker



Nonsmoker



- ◆ 흡연자의 경우 BMI 30을 기준으로 뚜렷한 차이가 발생하지만 비흡연자의 경우 차이가 보이지 않음
- ◆ 교호작용항을 사용하여 회귀분석 진행할 경우 Group1과 Group2를 설명하는데 한계가 있을 것으로 판단

02


변수 변환 및 정의

Interaction vs Group Dummy Variable

뚜렷한 차이를 보이지 않는 그룹을 합하여 다시 전체 데이터를 3개로 그룹핑

	BMI < 30	BMI >= 30
흡연 X	Group3	
흡연 O	Group2	Group1

종속변수 charges와 설명변수 age의 scatter plot을 확인한 결과 유의미한 그룹별 차이 발생



- 해당 plot을 근거로 **Dummy Variable**을 활용해 그룹 별로 Intercept를 다르게 설정하고자 함
- Group3은 구분선을 벗어나는 데이터가 다수 존재한다는 특징

02

변수 변환 및 정의

BMI Centering

bmi*smoke 교호작용 항 도입하여 regression 진행

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-2223.454	865.611	-2.569	0.01032	*
age	263.620	9.516	27.703	< 2e-16	***
sexmale	-500.146	266.518	-1.877	0.06079	.
bmi	23.533	25.601	0.919	0.35814	
smoke	-20415.611	1648.277	-12.386	< 2e-16	***
children	516.403	110.179	4.687	3.06e-06	***
regionnorthwest	-585.478	380.859	-1.537	0.12447	
regionsoutheast	-1210.131	382.750	-3.162	0.00160	**
regionsouthwest	-1231.108	382.218	-3.221	0.00131	**
bmi:smoke	1443.096	52.647	27.411	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- 상식과 달리 **smoke의 계수가 음수**
- 교호작용 항의 효과가 매우 크기에 발생한 결과로 예측
- 해석에 어려움 발생이 우려되어 **centering 진행**

centering

> summary(data\$bmi)

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
15.96	26.30	30.40	30.66	34.69	53.13


- **중위수 : 30.4 / 평균 : 30.66**
- **bmi 변수 전체에 중위수 값을 빼 centering 진행**
- **기존 설정한 비만의 기준(bmi 30)과 중위수 값이 유사하므로 centering bmi가 음수의 값을 가질 경우 정상, 양수의 값을 가질 경우 비만으로 해석**

02

변수 변환 및 정의

 age^2 , age^3

charges~age



- charges와 age는 이차 혹은 삼차함수 관계를 보임
- 따라서 age polynomial 항을 도입하여 분석 진행
- age³ 항을 포함하여 회귀분석을 진행한 결과, 설명력에 변동이 없었으며 age 변수 자체의 유의성도 사라짐
- age² 항만을 포함한 모델의 경우 변수가 유의하게 나타났으며 age만을 고려한 모델과 F-test를 진행한 결과 age² 항은 유의함


02

변수 변환 및 정의

log(charges)


charges

Histogram of Charges



log(charges)

Histogram of log(Charges)



- ◆ 종속변수 charges의 히스토그램을 보면 오른쪽 꼬리 형태 분포를 보이며 왼쪽으로 데이터가 쏠려 있음
- ◆ 잔차의 정규성 위배될 우려가 있어 로그 변환을 실시하여 모델링하는 것 고려 (변환 이후 정규분포와 유사한 형태)

분석 모형



03

분석 모형

변수 조합에 따른 9개의 모델 구성

1

All Variable Regression

2

Group Dummy Variable

3

Smoke * Bmi Interaction

4

Smoke * Bmi Interaction

Age²

5

Group Dummy Variable

Age²

6

log(Charges)

Smoke * Bmi Interaction

7

log(Charges)

Group Dummy Variable

8

log(Charges)

Smoke * Bmi Interaction

Age²

9


log(Charges)

Group Dummy Variable

Age²

Regressor	Y = charges					Y = log(charges)			
Model	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
age	256.9 *** (11.9)	263.6 *** (8.758)	263.6 *** (9.5)	-33.2 *** (64.6)	-12.9 (59.4)	0.03 *** (<0.001)	0.03 *** (<0.001)	0.05 *** (0.005)	0.05 *** (0.005)
ag2^2				3.7 (0.8)	3.4 *** (0.7)			-0.0002 ** (<0.001)	-0.0002 *** (<0.001)
bmi_med	339.2 *** (28.6)	59.8 ** (22.6)	23.5 (25.6)	20.1 (25.4)	57.1 * (22.4)	0.003 (0.002)	0.004 * (0.002)	0.003 (0.002)	0.004 * (0.002)
smoke	23848.5 *** (413.1)		23454.5 *** (330.6)	23465.7 *** (328.1)		1.54 *** (0.02)		1.54 *** (0.02)	
bmi_m*smoke			1443.1 *** (52.6)	1441.1 *** (52.2)		0.04 *** (0.004)		0.04 *** (0.004)	
sexmale	-131.3 (332.9)	-470.8 (245.2)	-500.1 (266.5)	-506.4 (264.5)	-476.3 (243.2)	-0.08 *** (0.02)	-0.086 *** (0.02)	-0.08 *** (0.02)	-0.085 *** (0.02)
children	475.5 *** (137.8)	508.5 *** (101.4)	516.4 *** (110.1)	675.1 *** (114.5)	656.3 *** (105.4)	0.1 *** (0.01)	0.1 *** (0.01)	0.09 *** (0.01)	0.09 *** (0.01)
regionnorthwest	-353.0 (476.3)	-274.8 (350.4)	-585.4 (380.8)	-599.3 (377.9)	-288.2 (347.7)	-0.07 * (0.03)	-0.06 (0.03)	-0.07 * (0.03)	-0.06 (0.03)
regionsoutheast	-1035.0 * (478.7)	-784.1 * (352.3)	-1210.1 ** (382.7)	-1206.5 ** (379.8)	-781.6 * (349.5)	-0.16 *** (0.03)	-0.14 *** (0.03)	-0.01 *** (0.03)	-0.14 *** (0.03)
regionsouthwest	-960.0 * (477.9)	-1154.5 ** (351.7)	-1231.1 ** (382.2)	-1228.3 ** (379.3)	-1151.8 *** (348.9)	-0.13 *** (0.03)	-0.13 *** (0.03)	-0.01 *** (0.03)	-0.13 *** (0.03)
g1		33177 *** (411.9)			33164.2 *** (408.7)		1.85 *** (0.04)		1.85 *** (0.04)
g2		13577.5 *** (431.4)			13612.5 *** (428.1)		1.22 *** (0.04)		1.22 *** (0.04)
(intercept)	-1627.1 ** (624.8)	-1728.5 *** (459.8)	-1508.1 ** (499.5)	3467.7 ** (1180.3)	2908.2 ** (1086.4)	7.44 *** (0.04)	7.43 *** (0.04)	7.12 *** (0.1)	7.1 *** (0.1)
SER	6062	4461	4846	4809	4426	0.4293	0.4242	0.4277	0.4225
Adjusted R^2	0.7494	0.8643	0.8398	0.8423	0.8664	0.7821	0.7871	0.7837	0.7889

변수선택법 및 모델 유의성 검정



04

변수선택법 및 모델 유의성 검정

진행 과정 개요

■ 변수 선택 과정

- 최적 모델 후보군의 변수를 일렬적으로 소거하며 Adjusted R^2 , Cp, AIC, BIC 값 도출
- BIC의 경우 AIC에 비해 변수의 개수에 패널티를 높게 부여하는 편
- 본 연구에서 사용하는 데이터 세트는 변수의 개수가 적은 편이므로
AIC를 기준으로 변수 선택 실시



■ 모델 유의성 검정 과정

- 최적 값을 도출한 모델을 Reduced Model로 설정한 후 Full Model과
F-test 진행하여 유의성 검정

04

변수선택법 및 모델 유의성 검정

Model 5



최적 모형 변수

- g1
- g2
- age_2
- sex_male
- bmi_med
- children
- region_southeast
- region_southwest



→ F-test 결과 Full Model과
유의한 차이는 발생하지 않음

	Variables	Number_of_parameter	Ad_R	Cp	AIC	BIC
991	g1, g2, age_2, sex_male, bmi_med, children, re...	9	0.866554	7.731577	22473.345682	22520.136063
418	g1, g2, age_2, children, region_southwest	6	0.865636	13.884171	22479.536556	22510.730143
1023	g1, g2, age, age_2, sex_male, bmi_med, childre...	11	0.866426	11.000000	22476.608244	22533.796487

04

변수선택법 및 모델 유의성 검정

Model 9



최적 모형 변수

- g1
- g2
- age
- age_2
- sex_male
- bmi_med
- children
- region_northwest
- region_southeast
- region_southwest

	Variables	Number_of_parameter	Ad_R	Cp	AIC	BIC
1023	g1, g2, age, age_2, sex_male, bmi_med, childre...	11	0.788873	11.000000	-2294.537505	-2237.349262
976	g1, g2, age, age_2, sex_male, children, region...	9	0.787950	14.814225	-2290.681612	-2243.891231

회귀진단 및 결론

05




05

회귀진단 및 결론

잔차 분석 - 등분산성

Model 5


Standardized Residual Plot



- fitted vaule에 따른 잔차의 경향성이 뚜렷하지 않음

Model 9

Standardized Residual Plot




- fitted vaule가 증가함에 따라 잔차의 분산이 줄어듦

05

회귀진단 및 결론


잔차 분석 - 정규성

Model 5



- 정규성 가정에 위배됨

Model 9



- 정규성 가정에 위배됨

05

회귀진단 및 결론

다중공선성 (VIF)

Model 5

```
> vif(lm5)
```

age_2	bmi_med	sex	g1	g2	children	southeast	southwest
1.016333	1.280502	1.010560	1.095187	1.097457	1.001592	1.244835	1.147982

Model 9

```
> vif(lm9)
```

age	age_2	sex	bmi_med	g1	g2	children	northwest
47.629882	47.582251	1.010644	1.280637	1.095878	1.097962	1.102096	1.518992
southeast	southwest						
1.652978	1.529831						

◆ 두 모델 모두 다중공선성 문제는 발생하지 않음


◆ 모델 9에서 age와 age^2의 VIF 값이 크지만 polynomial 항이기에 다중공선성 문제가 발생하지 않음

05

회귀진단 및 결론


이상치 (Cook's Distance)

Model 5



- 다수 극단치 발견

Model 9




- 다수 극단치 발견

- ◆ 종속변수 charges와 설명변수 age의 scatter plot에서 높은 charges의 값을 보이는 group3에 속하는 데이터가 대부분 이상치로 나타날 것이라 예측

05

회귀진단 및 결론

이상치 (Cook's Distance)



- 상위 100개의 outlier를 각 모델마다 추출해 plot을 그린 결과, Group3(초록)의 비율이 매우 큰 것 확인 가능
- 이는 charges~age scatter plot에서 설명되지 않지만 높은 charges의 값을 갖는 group3의 데이터가 이상치로 판별된 것이라 해석할 수 있음
- 극단치를 제거하고 회귀분석을 진행한 결과 설명력이 다소 높아지지만, 이상치 제거 근거가 부족하므로 실제 제거하지는 않음

최종 모델 선정 근거

- 모델 5와 모델 9는 진단 과정과 이상치에서 동일한 결과를 보임
- 설명력 : 모델 5 (0.8666) > 모델 9 (0.7889)
- 변수 자체의 유의성 면에서는 모델 9가 모델 5보다 앞섬
- 모델 5의 경우 변수 선택 과정에서 2개의 변수가 제거되었으나 모델 9는 어떠한 변수도 제거되지 않음
- 종속변수의 양을 설명하는 모델 5에 비해 모델 9는 보험료의 증가율을 설명하는 모델이기 때문이라 예측
- 본 연구의 주제는 개인의 리스크를 설명하는 유의한 모델을 찾고자 하는 것이므로 최종 모델은 모델 5로 선정
- 저량(stock) 시점이 아니라 기간 내 보험료의 증가분(flow)의 관점으로 분석 주제를 정했다면 모델 9를 최종 모델로 선정했을 것이지만, 데이터 자체의 변수 개수가 부족하다는 점, 변수 자체가 대부분 저량 변수인 점을 고려하여 일정 기간동안 보험료의 증가율을 분석 주제로 선정하기에는 다소 한계가 있다고 판단

05

회귀진단 및 결론

최종 모델 해석

```
> lm<- lm(charges~age_2+bmi_med+sex+g1+g2+children+southeast+southwest)
> summary(lm)
```

Call:

```
lm(formula = charges ~ age_2 + bmi_med + sex + g1 + g2 + children +
    southeast + southwest, data = data)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-4491.0 -1637.2 -1290.3  -846.8 24038.4
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2540.7657	313.1874	8.113	1.12e-15 ***
age_2	3.3276	0.1083	30.714	< 2e-16 ***
bmi_med	57.0111	22.4503	2.539	0.011216 *
sexmale	-475.1358	243.1669	-1.954	0.050917 .
g1	33172.8198	408.4006	81.226	< 2e-16 ***
g2	13615.3777	427.7739	31.828	< 2e-16 ***
children	646.9562	100.4414	6.441	1.65e-10 ***
southeast	-637.6871	303.2156	-2.103	0.035646 *
southwest	-1007.7633	302.1669	-3.335	0.000876 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4424 on 1329 degrees of freedom

Multiple R-squared: 0.8674, Adjusted R-squared: 0.8666

F-statistic: 1086 on 8 and 1329 DF, p-value: < 2.2e-16

- 비만과 흡연자에 모두 해당하는 경우 보험 가입자 개인의 리스크가 높게 측정되는 것을 회귀분석 결과를 통해 파악할 수 있음
- 한국간호학회지에 따르면 흡연자는 비흡연자에 비해 관상동맥 질환이 발병될 위험률이 2배 높음
- 또한 흡연자이면서 비만인 경우 비흡연자이며 정상체중인 사람에 비해 고지혈증 발병율이 7배나 높음
- 논문과 본 연구의 결과는 일맥상통함

분석 한계점 및 우수성



06

분석 한계점 및 우수성

분석 한계점

Omitted Variable 문제 (1)

- 미국의 민간 의료보험 특성상 직장생활 중 회사를 통해 사보험에 가입하는 경우가 일반적이며 소득 등의 외생적 변수에 따라 보험료의 차이가 발생할 가능성 존재
- 하지만 본 분석에 사용한 데이터 세트에는 소득이나 직장 여부 등 개인의 경제 활동과 관련한 변수가 없음
- 따라서 해당 데이터로는 경제적 요인에 의한 보험료의 영향을 측정할 수 없음

Omitted Variable 문제 (2)

- 자녀의 수의 경우 부모의 나이가 만 18세임에도 5명의 자녀가 있는 데이터가 관측되는 등 이상치로 의심되는 데이터가 발견되었으나 미국의 입양 제도 특성상 나타날 수 있는 것으로 해석
- 이 또한 결혼 여부 등의 변수가 부재하여 Omitted Variable 문제가 발생할 수 있다는 한계점 존재

06

분석 한계점 및 우수성

분석 한계점

생명표를 활용한 분석의 어려움

- 실제 보험사에서는 생명표를 활용하여 생명 보험료 산정
- 생명표의 사망 확률 변수 자체가 수량 변수(n 년도에서 $n+1$ 년도까지 사망할 확률)이며, 분석 시 사용한 데이터 세트에 인종, 직장 여부 등 개인적 특성이 반영된 변수가 없다는 점으로 인해 심층적 분석이 어렵다 판단
- 또한 데이터가 어떠한 상품군에 속하는 표본인지 알 수 없어 분석 진행 시 어려움 존재

데이터 세트의 특성으로 인한 한계점

- 미국은 주 별로 소득 수준이 상이하며 보험료와 상품군의 비율 또한 상이
- 본 분석에 사용하고자 하는 데이터 세트는 미국을 북동, 북서, 남동, 남서 총 네 부분으로만 구분지어 심층적 분석이 어렵다는 한계점이 존재

06

분석 한계점 및 우수성

분석 한계점

미국과 한국 보험 시장의 차이점으로 인한 한계점

- 한국 보험 시장의 경우 공공성의 성격이 강함
- 반면, 미국 의료보험은 사적 분야의 비중이 매우 크며 보험료 산정 시 개인의 리스크를 반영함
- 따라서 본 연구로 도출된 모델이 미국 시장의 보험자 리스크는 잘 설명하더라도
한국 보험 시장에 직접적으로 적용하기 어렵다는 한계점 존재

06

분석 한계점 및 우수성

분석 우수성

다양한 변수 변환 방법 활용

- 교호작용 항의 도입, Group Dummy Variable, Polynomial 항 도입, 종속변수에 대한 log 변환 등 다양한 변수 변환 방법을 활용하여 다각적 관점의 모델을 구성하고자 함

변수 선택 시 다양한 지수 및 시각화 활용

- 변수 선택 과정에서 Adjusted R square 뿐만 아니라 AIC, BIC, Cp 등 다양한 지수 및 시각화 방식을 활용하여 변수 선택 과정의 신뢰도를 높이하고자 함

현실에 적용할 수 있는 모델이 통계적 과정을 통해 선정

- 본 연구를 통해 선정된 모델 해석 결과와 한국간호학회지 논문 내용이 일치함