


영화의 흥행 요인 분석



201711726 응용통계학과 이준우

I 서론

코로나 19는 초유의 사태이며, 여러 방면에서 큰 영향을 끼쳤다. 2020년에는 미국, 영국과 같은 주요국가들의 재정적자가 GDP의 10%를 상회하였으며, 세계 경제가 둔화하면서 경제성장률도 감소하였다(2020년 2/4분기 기준 한국 경제성장률은 -3.3%였다). 경제뿐만 아니라, 코로나 19는 삶의 전반적인 부분에 변화를 가져왔다. 해외여행이 어려워졌고, 문화 활동에 제약이 생겼다. 팬데믹으로 인해 여가 활동에 큰 부분인 문화예술, 관광, 스포츠산업이 경제적 타격을 입었다. 특히, 영화 산업이 극심한 타격을 입었다. 또한, 코로나 19는 영화 산업의 위축뿐만 아니라, 전반적인 산업의 구조를 변화를 야기하였다고 한다. 이에 관하여, 기존의 영화 산업 구조를 파악하고, 실제로 산업 전반의 많은 변화가 일어났는지 알아보려고 하였다. 또한, 영화의 흥행 요인은 어떠한 것인지 알아보려고 하였다.



※ 기존 연구

영화 흥행에 관하여 초기에 연구한 ¹⁾Litman은 제작비, 상영관 수, 평점, 배급사의 영향력 등과 같은 변인들로 회귀분석을 행하였다. 연구를 통해, 제작비와 상영관 수가 영화의 흥행에 유의한 영향을 주고 있다는 결론에 도달하였다. 이후, Litman은 상영관 수, 제작비, 장르의 변인을 통해 설명변수에 관하여 적절히 소개하였고, ²⁾Wyatt는 개봉 시기의 변인을 추가하여, 설명력을 더하였다. 또한, 요즘은 온라인 구절에 관한 변수를 통하여 영화의 흥행성을 설명하려는 연구가 진행되고 있다. 그리고, 이를 바탕으로, 영화의 흥행성을 예측하는 모델을 생성하기도 한다.

* 데이터(영화)의 특성:

³⁾영화는 경험재적 특성을 지니고 있다. 관람하기 전까지는 그 특성을 알 수 없고, 관람하고 나서야 평가가 가능하기 때문이다. 그렇기에 잘못된 선택을 하지 않기 위해, 정보의존도를 높인다. 그렇기에 영화 구전 정보에 의존하며, 요즘은 인터넷을 통한 구전 정보에 크게 의존한다. 영화는 다른 예술 분야에 비해 제작에 오랜 시간이 들며, 투자-제작-배급의 구조를 결친 사업이다. 영화의 성공에 관하여 크게 작품성과 흥행성으로 나뉘는데, 전자는 독립영화에 관심을 두고 있으며, 후자는 상업 영화에 초점이 맞춰져 있다. 흥행성의 기준은 매출액과 관객 수를 기준으로 삼고 있다.

* 영화 산업의 구조변화:

야외 활동보다는 집에 있게 되면서 영화관보다는 넷플릭스, 왓챠와 같은 OTT서비스를 자주 이용하게 되었다. 그리고 이 현상으로 인해, 대형 상영사 중심의 콘텐츠가 ⁴⁾OTT서비스 중심의 콘텐츠로 전환하였다. 이러한 변화의 물결에서 콘텐츠에 관한 데이터를 분석하여 인사이트를 얻고자 하였다. 또한, 과거에는 수입, 배급에만 참여하던 대형 영화사들이 제작-(수입)-배급의 영화 전 과정을 일임하는 현상이 점점 증가하고 있는 추세이다.

1) Litman B. R., "Predicting success of theatrical movies: An empirical study", The Journal of Popular Culture, 제16권 제4호, pp. 159-175, 1983.
 2) R. O. Wyatt and D. P. Badger, "Effects of information and evaluation in film criticism," Journalism Quarterly, Vol.67, No.2, pp.359-368, 1990.
 3) 전범수, "영화 소비 결정 요인" 한국콘텐츠학회논문지, 제13권 제10호, pp.226-233, 2013.
 4) 정서현, 박주연(2021), 영화관람 매체 간 경쟁관계 적소분석 영화관, 유료방송 VOD, OTT를 중심으로 정보사회와 미디어, 22(3), 149-177.

※분석 주요점

1. 영화의 흥행 요인은 무엇인가?

1. 제작비, 작품성(평점), 스크린 수를 중심으로 분석
2. 영화를 제작한 감독의 수상 실적을 중심으로 분석

2. 코로나 19 이전과 이후 흥행에 큰 차이가 있는가?

3. 영화 산업 전반의 구조적인 변화는 일어났는가?

1. 기존 메이저 영화사를 중심으로 분석
2. 변모하는 플랫폼 생태계(OTT)를 중심으로 분석

II 변인 정의 및 분석 계획

영화 산업의 전반적인 흐름은 과거에도 미국이었고, 지금도 미국을 중심으로 돌아간다. 중국과 인도가 막강한 자본력을 바탕으로, 미국 중심의 영화 구조에 변화를 꾀고 있지만, 전 세계적으로 미국이 우위를 점하고 있음은 여전하다. 영화 산업의 전반적인 흐름을 알아보고자 하였기에, 미국 영화 산업 데이터를 대상으로 분석을 실시하였다. 'IMDB'의 API시스템을 활용하여, 미국의 연간 박스오피스 데이터 40년치(1980~2020상반기)를 분석 대상 데이터로 추출하였고, 보조적인 정보가 필요하여 일부의 데이터는 'Numbers'의 데이터를 추출하여, 분석에 사용하였다.

iMDB Data : 1980-2020 UAS Box office movie(5420) & Numbers(Director's award, Score)

1.numeric var

- Gross: 영화의 수익(Y) (단위 / 10000\$)
- Budget(M) : 영화 순 제작비 (PR비는 제외)(단위 / 10000\$)
- Score : 영화에 관한 평점(1~10 / Rotten Tomato)
- Votes(M) : 영화 관객수(스크린수와 비슷한 변수로 취급)(단위 / 10000명)
- Award : 감독이 수상한 횟수

2.catrgorical var

- Company : 제작한 회사명
- Ott service : Ott 서비스 지원 영화(Binary)

우리나라 영화 산업의 전반적인 형태를 알고, 전반적인 세계 흐름에 부응하는지 알아보하고자 하였다. 따라서, 영화진흥원의 데이터를 보조적으로 활용하여 이를 분석에 활용하였다.

한국 영화 진흥원(KOBIS)(2019-2022)


1.numeric var

- Revenue : 영화의 수익(Y) (단위 / 원)
- Screen: 영화 상영 스크린의 수
- People: 영화 관람객 수(단위 / 명)

2.catrgorical var

- Ind film : 독립 영화(Binary)


III 데이터 파악




> c(summary(y),Var=var(y))

Min	1st Qu	Median	Mean	3rd Qu	Max	Var
0.030	1068.915	3674.425	10296.469	11198.682	284724.620	349513508.421


영화 수익의 전반적인 분포는 오른쪽으로 강한 꼬리를 지닌 형태이다. 또한, 상자그림 상에서 이상점으로 판별 되는 지점에 많은 표본이 위치되어 있다. 위의 그래프에서 볼 수 있듯, $Q3+1.5*IQR$ 지점(26393.3325)을 상회하는 표본이 많이 있다. 극단값의 영향으로 분산은 18695.28^2 이며, 이는 매우 큰 값이다.



시간이 지나면서, 영화 수익은 더 가파른 상승세를 띄며 증가하고 있다. 특히, 2000년대에는 이전과 다른 양상으로 더 가파른 상승세를 지니고 있다.(2020년의 자료는 상반기 일부 자료만을 한정하였기에, 극단적으로 높은 중위수 값이 도출되었다.)



상영관수~매출액(빨강-코로나 이후 / 파랑-코로나 이전)



코로나 이전

코로나 이후


코로나19 이전 매출액					
MIN	Q1	MED	Q3	MAX	Var
1.0	276.0	585.0	973.0	2835.0	273696.3

코로나19 이후 매출액					
MIN	Q1	MED	Q3	MAX	Var
1.0	131.5	276.0	691.5	2948.0	271326.5

한국의 박스 오피스 데이터를 바탕으로 작성한 산점도이다. 그래프에서 보듯, 영화의 수익이 코로나 이전에 비해, 많이 줄어들었고, 스크린 수도 이전의 데이터에 비해 적게 분포된 표본이 많았었다. 영화 수익의 중위수가 약 1.98배 감소하였으며, 분산에는 그다지 큰 변동이 없었다. 한국 영화 시장은 전반적으로 위축되었고, 아직 뚜렷한 양의 회복세를 띄지는 않는다. 다만, 이는 세계적으로 전반적인 영화 시장에 대입하기에는 다소 무리가 있다. 5) 왜냐하면, 미국과 중국의 영화 시장은 벌써 코로나 이전의 최대 수익을 상회하였으며, 이미 양의 회복세를 띄고 있다. 또한, 중국, 인도 영화 산업은 전해 연도에 대비하여 100% 이상의 괄목한 성장을 거두었다. 따라서, 영화 산업 전반의 변화를 파악하는 분석에서 한국 박스 오피스 자료는 고려 대상에서 제외하였다.

5) KOFIC영화진흥위원회, “2021년 한국 영화 산업 결산” KOFIC연구 2022-02, pp.1~10, 2022.

IV데이터 분석




위 자료에서 볼 수 있듯, 2011년은 1981년에 비해, 극단 값의 편차가 매우 크다. 2011년도 영화의 수익 중위수는 약 8,044(10,000\$)이며, 1981년도 영화의 수익 중위수는 1,757(10,000\$)인데, 이는 3.26배의 증가세를 띄고 있다. 연간 영화의 최대 값과 중위수의 차이도 해를 거듭할수록 더 커져간다.

모든 수치형 변수들을 plot해본 결과, 수익에 양의(+)관계를 보이고 있다. 특히, 제작비, 관객수(스크린 수)의 변수는 영화 수익에 상대적으로 강한 양의 관계를 지니고 있다.

> cor(gross,x) : x other var

score	budget	votes	gross	runtime
0.2225604	0.7396548	0.6147695	1.0000000	0.2741166




제일 상관관계가 높은 제작비와 수익 간의 산점도를 그려보았다. 그리고 수익을 기준으로 12개의 그룹으로 분류하여, 색을 달리 표현하였으며, 히스토그램으로 가시화 해보았다. 모든 그룹이 동질적인 분포를 띄었으며, 대체로 오른쪽으로 꼬리 형태를 이루는 경향성을 관찰할 수 있었다.

$$\hat{Y} = -1675.33 + 3.33X_{Budget}$$

수익과 제작비 간의 변수만을 고려하여 선형 회귀분석을 시행해 본 결과 위와 같은 회귀 계수가 나왔다. 설명력은 0.5471이며, 0.05유의 수준 하에서 제작 변수에 관한 회귀 계수가 유의하게 나왔다.

$$\hat{Y} = -1657.32 + 661.78X_{Score} + 2.69X_{Budget} + 359.87X_{Votes} - 56.43X_{Runtime}$$

다음은, 수익을 영화의 평점, 제작비, 관객수, 상영시간을 설명 변인으로 설정하여 선형 회귀식을 유도하였다. 영화에 관한 평점이 1단위 증가할 때마다, 661.78(10000\$)만큼의 수익 추정치가 증가하며, 제작비가 1(10000\$)단위 증가할 때마다, 수익이 2.69(10000\$)만큼 증가함을 볼 수 있었다. 설명력은 0.6534이며, 상영 시간을 제외한 모든 변인이 유의 수준 0.05하에서 유의하게 나왔다.



월간 추이 변동에는 변화가 없는지 알아보기 위해, 2000년대 이전과 이후를 분류하여, 상자그림을 그려보았다. (변화의 정도를 확인하기 위해, 일부 극단적인 값들은 표에서 제거하였다.) 대체로 6-7월에 흥행하는 영화가 많이 위치해 있으며, 이 시점의 표본은 다른 달의 자료에 비해 높은 수익을 지니고 있다. 2000년대 전후로 월간 추이에 대한 유의미한 변동은 찾아보기 어려웠다.

$$\hat{Y} = 3064.73 - 52.25X_2 + 469.45X_3 - 344.88X_4 + 4730.33X_5 + 8063.59X_6 + 5038.94X_7 + 156.30X_8 - 139.86X_9 - 124.38X_{10} + 3835.98X_{11} + 4656.45X_{12}$$

월별로 데이터를 구분하여, 수익성에 유의미한 영향을 주는지 회귀식을 생성해 보았다. 어떠한 변수를 더미변수로 지정하여도 그다지 설명력이 좋지 않았으며($r_squared = 0.09$), 시계열 자료에 관한 내용이었기에, 분석에 관한 변수로 사용하기는 어렵다고 판단하였다.


> summary(subset(data1, big5==1)\$gross)

Min	1st Qu	Median	Mean	3rd Qu	Max
0.51	3541.05	9644.04	19055.54	21994.71	279750.13


> summary(subset(data1, big5==0)\$gross)

Min	1st Qu	Median	Mean	3rd Qu	Max
0.03	817.63	2769.87	8081.44	8626.47	284724.62


미국의 메이저 5대 영화사는 미국 박스오피스의 수익의 75% 정도를 차지 할 정도로 매우 거대한 규모를 지니고 있다. 이들의 영화 수익 중위수는 9644.04(10000\$)이며, 다른 영화사에 비해 매우 큰 수치이다. 코로나19 이전과 이후에 자료를 비교해보아도, 메이저 영화사의 수익 비중은 큰 변동이 없으며, 코로나 19가 기존의 소수 영화사의 독과점 구조에 변화를 일으켰다고 보기에는 다소 무리가 있다.




대표적인 종속변수와 독립변수인 영화 수익과 제작비에 분포형태가 오른쪽으로 강하게 치우쳐져 있었다. 또한, 이 두 개의 변수는 다른 설명변인보다 비교적 큰 규모의 단위를 가지고 있어서, $\log()$ 변환을 이용하여 변수 변환을 실행하였다. 변수 변환 이후 이 둘의 히스토그램은 비교적 대칭성을 띤 정규분포의 형태와 유사하게 바뀌었다.




앞서 설명한 바와 같이, 영화의 제작비와 수익의 구조는 강한 오른쪽 꼬리 형태를 띄고 있다. 그렇기에, 흥행성을 수익/제작비의 정도로 정의한다면, 적은 수익에도 불구하고, 오히려 더 작은 제작비로 인해, 높은 흥행성을 지닌다 오판되는 표본자료가 발생했을 것을 예상하였다. 이 같은 왜곡을 막고자, $\text{success}(\text{수익}/\text{제작비})$ 변수를 생성하여, 제작비~success 산점도를 만들어 보았다. 두 개의 군집으로 확인한 차이가 낮았고, 빨간 부분의 표본점은 분석 대상에서 제외하였다.




추가적으로, OTT 콘텐츠와 메이저 영화사의 제작 유무를 기준으로 4개의 집단으로 구분하여, 상자그림을 그려 보았다. 역시나, 모두 오른쪽으로 꼬리가 길게 있는 형태이며, 메이저 영화사가 제작한 표본 그룹인 G1, G2가 상대적으로 높은 수익의 수치를 보여주고 있었다.



초기 모형은 기존에 하였던 것과 같이 제작비~수익의 모형으로 회귀분석을 실시하였다. 제작비 변수는 t값이 19.958로 매우 유의한 수준의 영향을 주고 있으며, F값 또한 매우 유의한 수준이 관측되었다. 모형에 대한 설명력은 0.5002로 저조한 수준의 설명력을 보여주었다. 아무래도, 범주형 변인(장르)과 시계열 변인(개봉 일주일 간 점유율)을 사용하지 않았기에 이런 결과가 나왔으리라 예상된다.



이번에는 Full mode로 회귀분석을 실행해 보았다. 여기서 OTT와 Big5는 binary var로, 영화 상영시간과 마찬가지로, 자료에 그리 크게 영향을 준다고 보기 어렵다.(물론, 유의수준 0.05하에서, OTT와 상영시간은 유의하다.) F통계량 값도 계산 결과 0.05의 유의 수준 하에서 유의한 모형으로 나왔다. 설명력은 0.523으로 일부 증가하였다.




후진제거법을 이용하여, 모델의 불필요한 설명 변인들을 제거하였다. 최종적으로, (평점, 예산, 관객수, 상영 시간, OTT, BIG5)의

변수가 설명변인으로 채택되었다. 그리고 이들의 다중 공선성은 존재함이 그리 유의하지 않은 것으로 관측되었다.(VIF<10) Cook distance test 결과 2개의 이상치가 관측되었고, 이들을 제거한 상태에서 다시 새로운 회귀식을 설정하였다. 이전 식과 다르게 OTT변수가 더욱 유의해 졌고, 설명력 또한 0.6205로 상승하였다. 표준화된 잔차 산점도를 그려보면, 대부분이 -2와 2 사이에 위치해 있었다.

```
> x<-outlierest(model2)#4,159 idx
> x
      rstudent unadjusted p-value Bonferroni p
4      -5.580548      0.000000044808 0.000017923
159    -4.150780      0.000040674000 0.016270000
Coefficients:
              Estimate Std. Error t value      Pr(>|t|)
(Intercept) -0.393124    0.678800  -0.579      0.5628
score        0.197635    0.085917   2.300      0.0220 *
budget       0.981416    0.064036  15.326    < 2e-16 ***
votes        0.033093    0.004551   7.271 0.00000000000196 ***
runtime     -0.008249    0.004317  -1.911     0.0567 .
OTT          0.310530    0.125251   2.479     0.0136 *
big5         0.245685    0.169611   1.449     0.1483
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 1.202 on 391 degrees of freedom
Multiple R-squared:  0.6205,    Adjusted R-squared:  0.6147
F-statistic: 106.6 on 6 and 391 DF,  p-value: < 2.2e-16
```



V 결론 및 한계

코로나19로 인한 여러 변화가 있었지만, 코로나 19는 영화 산업계에 제동을 가져왔을 뿐, 기존의 소수 영화사의 독과점 체제의 변모를 이끌지는 못했다. 또한, 미국, 중국, 인도의 영화 산업과 다르게, 우리나라의 영화 산업은 여전히 코로나 19의 타격에서 벗어 나지 못하고 있는 것을 알 수 있었다. Litman의 기존 연구대로, 영화의 흥행에 있어 제작과 스크린 수는 유의한 영향을 주었음을 알 수 있었다.

다만 분석 대상 자료가 40년치의 자료이기에 인플레이션의 영향도 무시할 수 없다. 나아가, 영화의 연간 수익 향상이 영화 산업의 성장이 아니라, 인플레이션에 의해 야기되었다 해석할 수도 있다. 하지만, 이 같은 해석에는 오류가 존재한다. 미국의 물가 상승률의 그래프를 보면, 80년대 초반에 극심한 인플레이션을 겪다가, 중반에 다다르면서, 점차 안정적으로 되었다. 하지만 영화의 수익 그래프를 보면, 인플레이션에 상관없이, 지속적으로 우상향하고 있다. 또한, 연간 영화 수익의 중위수는 그리 크게 증가하지는 않지만, 극단적인 표본들의 값이 점점 높아지고 있다. 특히 2000년대에 들어서 영화 수익성의 격차는 점점 커지고 있다. 따라서, 인플레이션이 영화의 수익성에 그리 지대한 영향을 미쳤다고 보기는 어렵다.



예나 지금이나 영화산업 시장은 소수의 대형 영화사에 의해 주도되는 과점시장의 형태를 띄고 있다. 2019년 기준으로 월트 디즈니사가 미국 전체 영화 시장 수익의 33.15%를, 이어 워너 브라더스사가 13.91%를, 컬럼비아사가 12.18%를, 유니버설사가 11.5%를, 파라마운트사가 5%를 차지하고 있다. 5개의 대형 영화사가 약 전체적인 수익의 75%를 차지하고 있다. 영화 산업이 소수 메이저 영화사의 과점 시장이 된 것에는 영화산업사와 영화의 특징에서 원인을 찾을 수 있다.

영화는 타 미디어 상품과 다르게 제작과 기획에 있어 시간과 비용이 많이 들어간다. 또한, 영화는 “기획-제작-배급”의 과정을 거쳐 소비자에게 오는데, 배급에 있어서도, 천문학적 비용이 들어간다. 그렇기에 영화 제작은 진입 장벽이 높은 분야이다. 또한, 영화라는 상품은 보기 전까지는 알지 못하는 소모적이며 일회적인 특성을 지닌다. 그렇기에 사람들은 합리적인 선택을 하기 위해, 영화에 대한 정보에 크게 의존하게 된다. 영화의 홍보, 상영관에서의 점유율이 이러한 이유로 영화 흥행에 큰 영향을 미치고, 이러한 구조 특성상 대형 영화사가 소규모 영화사보다 유리한 구도에 있다.

1920년을 전후해서 시작된 미국의 영화산업은 1948년을 기점으로 과도하게 성장하였다. 하지만, 미국 정부의 메이저 영화사 과점 방지와, 텔레비전 보급으로 인하여, 영화 산업은 위축 되었다. 그러나, 1990년대 이후로 점차 영화 산업에 대한 규제가 풀리고, 대형 미디어 회사들이 인수합병을 하면서, 영화 산업은 이전과 다른 국면으로 변화였다. 소수의 메이저 영화사를 주도로 한 규모의 경제가 실현되었다. 그리고 이로 인해 연간 영화 수익의 극단 값이 예전과 다르게 급격히 올랐다.

플랫폼의 중심이 OTT로 변모되어도, 영상 콘텐츠의 제작-배급 구조는, 이전과 다른 양상으로 변모하였다 보기 어렵다 판단하였다. 다만, OTT 시스템이 더욱 활성화하여, 영화 시스템 전반에 변화가 발생한다면, 기존 영화 흥행성에 대한 요인적 설명이 다소 힘이 떨어질 수 있다. 따라서, OTT변수와 더하여 온라인 구절에 관한 변수를 통한 흥행 요인 설명이 필요하다고 생각한다.

영화의 흥행에 관하여, 장르도 매우 중요한 요인으로 작용한다. 다만, 범주형 변인에 관하여 처리가 매우 어려워서 이를 고려 대상에서 제외하였고, 이로 인해 좋은 설명력을 지닌 모델을 만들어내지 못했던 것 같다. 더하여, 영화 흥행성에 관한 논문에서, 개봉 이후 일주일 내의 영화 스크린수, 점유율이 흥행에 있어 중요한 요인이라는 결과를 보았었는데, 시점에 관한 자료에 대해 분석하지 못한 것이 한계점이었다. 또, 기존에 분석 주요점으로 여겼던 OTT와 메이저 영화사의 변수 설정과 분석이 매우 미흡했던 것 또한 한계점으로 작용하였다.

<부록 / 분석에 사용한 R코드>

```
rm(list = ls())

#Download and load packages.
download.packages('readxl')
library(readxl)

#Load IDMB data
movie<-read_excel("/Users/kong_bro/Desktop/termpj/filming_data/movies.xlsx")
str(movie)

#Filtering numeric datas
data1<-movie[,c("score","budget","votes","gross","runtime")]

#Base(y)
y<- as.numeric(as.matrix(movie[,c("gross")]))
y_year<-movie[,c("gross","year")]

y_year$year<-as.factor(y_year$year)
n<-levels(y_year$year)

#3p “전체전인 영화 수익 히스토그램”
hist(y,main="Movie Revenue",xlab = "Revenue")
#3p “전체전인 영화 수익 상자그림”
boxplot(y,horizontal = T,main="Movie Revenue")
c(summary(y),Var=var(y))

#3p “전체적인 영화 수익 중위수 산점도”
yearmed<-data.frame()
for (i in 1980:2019){
  c<-median(subset(y_year,y_year$year==i,select = gross)$gross)
  yearmed<- rbind(yearmed,c)
}

rownames(yearmed)<-(1980:2019)
colnames(yearmed)="med"

plot(n,yearmed$med,ylab="Med(year)",xlab = "Year",main = "Plot of year med")
abline(v=2000,lty=3)

#3p “전체적인 영화 수익 분산 산점도”
var(y_year)
y_year$year<-as.factor(y_year$year)
n<-levels(y_year$year)
str(y_year)

yearvar<-data.frame()
for (i in 1980:2020){
  c<-var(subset(y_year,y_year$year==i,select = gross)$gross)
  yearvar<- rbind(yearvar,c)
}

rownames(yearvar)<-n
colnames(yearvar)="var"
plot(n,yearvar$var,ylab="Var(year)",xlab = "Year",main = "Plot of year var")
abline(v=2000,lty=3)

#Load KOBIS data
film<-read_excel("/Users/kong_bro/Desktop/termpj/filming_data/all.xlsx")

#covid clustering
film_covid<-film[film$covid==1,]
film_ncovid<-film[film$covid==0,]

#4p “상영관수~매출액(코로나 19 이전 이후) 산점도
y1<- film_covid$revenue
```

```

x1<- film_covid$screen
y2<- film_ncovid$revenue
x2<- film_ncovid$screen
plot(c(0,max(film$screen)),c(0,max(film$revenue)),col='white',main="Movie Covid",xlab='screen',ylab = 'revenue')
points(x1,y1,col='blue')
points(x2,y2,col='red')

#5p "상영관수~매출액(코로나 19 이전) 산점도
plot(x1,y1,main="Covid Aft movie",xlab='screen',ylab = 'revenue')

#5p "상영관수~매출액(코로나 19 이후) 산점도
plot(x2,y2,main="Covid Bf movie",xlab='screen',ylab = 'revenue')
c(summary(x1),var(x1))
c(summary(x2),var(x2))

#Ordering IDMB data by gross
datum<-data1[order(data1$gross),]
#Grouping data(13 groups)
datum <- cbind(datum, g=(round(seq(1,13,length.out = nrow(datum))))))

#Y-year1981&2011
y_2<-subset(y_year,y_year$year==c(1981,2011))
#7p "1981년도&2011년도 영화상자 그림"
boxplot(y_2$gross~y_2$year,main="Revenue Boxplot(Y1981&2011)",horizontal = T,ylab = "Year",xlab = "Revenue")

#5p "영화 데이터 전반적인 변수 산점도"
plot(datum,main="Numeric Var ~ Revenue")

cor(datum)[,"gross"]

#5p "제작비~수익 간의 산점도 및 회귀 곡선"
plot(budget,gross,main = "Budget~Revenue", col=datum$g, cex=.2)
abline(lm(gross~budget))

#5p "수익 그룹별 히스토그램"
par(mfrow=c(3,4))
for (i in 1:12){
  hist(datum[datum$g==i,"gross"],main=i,xlab="g",ylab="Fq")
}

#5p budget~Y regression
summary(lm(gross~budget))
anova(lm(gross~budget))

#6p X~Y regression
summary(lm(gross~.-g,data=datum))
anova(lm(gross~.-g,data=datum))

#Load IDMB data add month var!
data2<-movie[,c("score","budget","votes","gross","runtime","month","year")]

#Grouping data (2000bf&af)
data_20<-subset(data2,data2$year<=1999)
data_21<-subset(data2,data2$year>=2000)

data_20$month<-as.numeric(data_20$month)
data_21$month<-as.numeric(data_21$month)

#Ordering data (revenue)
data_20<-data_20[order(data_20$month),]
data_21<-data_21[order(data_21$month),]

#6p "2000년대 이전 월간 영화 수익 상자그림"
boxplot(data_20$gross~data_20$month,main="(1980~1999)",xlab="Month",ylab = "Revenue",outline=F)
#6p "2000년대 이전 월간 영화 수익 상자그림"

```

```

boxplot(data_21$gross~data_21$month,main="(2000~2020)",xlab="Month",ylab = "Revenue",outline=F)

datum<-movie[,c("gross","month")]

#6p month(bin)~Y regression
for(i in 1:12){
  i <- (datum$month==i)*1
  datum<-cbind(datum,i)
}

colnames(datum)<-c("gross","month",paste('M',c(1:12),sep = ""))
datum$month<-NULL

summary(lm(gross~.-M1,data = datum))

#Load IDMB data add big5(month) var!
data1<-movie[,c("gross","budget","awards","big5","OTT","score")]

summary(subset(data1,big5==1)$gross)
summary(subset(data1,big5==0)$gross)

data1$O<-ifelse(data1$OTT>=1,1,0)
head(data1)
data1$G<-ifelse(data1$O==1,ifelse(data1$big5==1,1,3),ifelse(data1$big5==1,2,4))

boxplot(data1$gross~data1$G,horizontal = T,main="OTT&BIG5",xlab = "Revenue",ylab = "Group")

plot(data1$budget,data1$gross,col=data1$big5+1,cex=0.3)

plot(data1$gross~data1$budget)
model1<-lm(data1$gross~data1$budget)
abline(model1)
summary(model1)

summary(subset(data1,G==1)$gross)
summary(subset(data1,G==2)$gross)
summary(subset(data1,G==3)$gross)
summary(subset(data1,G==4)$gross)

#7p “연간 영화 수익 상자그림”
y_year<-movie[,c("gross","year")]
boxplot(y_year$gross~y_year$year,main="Revenue Boxplot(Year)",xlab = "Year",ylab = "Revenue")

#Regression Analysis
data1<-movie[,c("score","budget","votes","gross","runtime","awards","OTT","big5","usa")]

data1$O<-ifelse(data1$OTT>=1,1,0)
#suc var
data1$suc<-ifelse(data1$gross/data1$budget>=30,1,0)

plot(data1$budget,data1$gross,col=data1$suc+1,cex=0.5)
#Eliminating suc
data1<-subset(data1,suc==0)

datum<-data1[sample(c(1:5300),400),]

hist(datum$gross)
hist(datum$budget)

#log(gross), log(budget)
datum$gross<-log(datum$gross)
datum$budget<-log(datum$budget)

#model1
attach(datum)
plot(gross~budget,col=big5+1,cex=.5,main="gross~budget")

```

```

model1<-lm(gross~budget)
abline(model1)
summary(model1)
anova(model1)

rs<-rstandard(model1)
plot(rs,col=big5+1,cex=.5,main = "Residual")
abline(0,0,col=3)
abline(-2,0,col=3,lty=2)
abline(2,0,col=3,lty=2)

#model2
model2<-lm(gross~score+budget+votes+runtime+OTT+big5)
summary(model2)
anova(model2)
step(model2)

vif(model2)

rs<-rstandard(model2)
plot(rs,col=big5+1,cex=.5,main = "Residual")
abline(0,0,col=3)
abline(-2,0,col=3,lty=2)
abline(2,0,col=3,lty=2)

library(olsrr)
ols_plot_cooksd_bar(model2)

x<-outlierTest(model2)#4,159 idx

datum_or<-datum[-c(4,159),]
#model3
model3<-lm(gross~score+budget+votes+runtime+OTT+big5,data = datum_or)
summary(model3)

rs<-rstandard(model3)
plot(rs,col=big5+1,cex=.5,main = "Residual")
abline(0,0,col=3)
abline(-2,0,col=3,lty=2)
abline(2,0,col=3,lty=2)

```